Machine Translated by Google

Aandacht is niet alles wat je nodig hebt: slaap, geheugen, leerstof en vloeistofdynamiek in taalverwerving.

Joep van Opdorp

Maart 2026

Machine Translated by Google

1 Inleiding

Grote taalmodellen hebben de afgelopen jaren opmerkelijke vooruitgang geboekt, maar hun leerdynamiek verschilt fundamenteel van die van mensen.
Hoewel mensen taal verwerven door geleidelijke blootstelling, gestructureerde leerplannen, episodisch geheugen, relationeel redeneren en slaapgestuurde consolidatie, zijn moderne neurale architecturen bijna uitsluitend gebaseerd op statische trainingsregimes, enorme datasets en op aandacht gebaseerde mechanismen. Als gevolg hiervan hebben huidige modellen moeite met continu leren, lijden ze onder catastrofale interferentie en missen ze de flexibiliteit en het gestructureerde begrip die kenmerkend zijn voor menselijke cognitie.

De Transformer-architectuur introduceerde het aandachtmechanisme als een krachtig instrument voor sequentiemodellering, maar aandacht alleen omvat niet het volledige spectrum van biologisch leren. Mensen richten zich niet alleen op aandacht; ze onthouden, consolideren, reorganiseren en herinterpreteren ervaringen in de loop van de tijd. Ze bouwen relationele structuren op, breiden hun woordenschat dynamisch uit en vertrouwen op slaap om nieuw verworven kennis te stabiliseren en te verfijnen. Deze processen ontbreken grotendeels in hedendaagse taalmodellen, waardoor hun vermogen om efficiënt en robuust te leren in dynamische omgevingen wordt beperkt.

In dit werk presenteren we een alternatief perspectief op taalverwerving: een dualistisch, vloeibaar taalmodel dat principes integreert die geïnspireerd zijn door de menselijke cognitie. Onze architectuur combineert vloeibare neurale dynamiek voor adaptief representatieleren, een hippocampus-achtige episodische buffer voor snelle geheugenvorming, slaap-geïnspireerde consolidatie via een gespiegeld hulpmodel, een relationeel wereldmodel voor gestructureerde kennis en een dynamisch uitbreidende tokenizer die meegroeit met ervaring. Samen maken deze componenten een vorm van continue taalverwerving mogelijk die stabieler, interpreteerbaarder en biologisch onderbouwd is.

We tonen aan dat de integratie van slaap, geheugen, leerstof en vloeistofdynamica leidt tot verbeterde generalisatie, minder vergeetachtigheid en een robuustere verwerving van taalstructuren. Onze resultaten suggereren dat aandacht weliswaar een waardevol mechanisme blijft, maar niet het enige dat nodig is om een mensachtige taalverwerving te bereiken. Hoewel het model niet bedoeld is als een complete oplossing of een stap richting algemene kunstmatige intelligentie, vertegenwoordigt het een zinvolle en biologisch gemotiveerde vooruitgang in het voortdurende leerproces van talen.

Machine Translated by Google

2 Dynamische tokenizer

Om continu taal leren te ondersteunen, implementeren we een eenvoudige dynamische tokenizer die zijn woordenschat uitbreidt naarmate het model nieuwe woorden tegenkomt. In tegenstelling tot moderne, op subwoorden gebaseerde tokenizers zoals BPE of Unigrams, is onze tokenizer opzettelijk minimalistisch en primair ontworpen als een proof of concept. Het doel is niet om state-of-the-art compressie of dekking te bereiken, maar om te demonstreren hoe een model zijn woordenschat in de loop van de tijd kan uitbreiden op een biologisch geïnspireerde manier.
wijze.

De tokenizer begint met slechts twee speciale tokens, <pad> en <unk>, en bouwt zijn vocabulaire op door volledige woorden in het trainingscorpus te observeren. Tijdens een initiële trainingsfase worden woorden die boven een bepaalde frequentiedrempel voorkomen, toegevoegd als tokens voor hele woorden, elk voorafgegaan door de aangewezen markering om woordgrenzen aan te geven. Deze prefixstrategie is geïnspireerd op SentencePiece, maar is in een veel eenvoudigere vorm geïmplementeerd.

Na de initialisatie blijft de tokenizer zichzelf tijdens het leerproces bijwerken. Wanneer het model nieuwe zinnen tegenkomt, worden de woordfrequenties bijgewerkt en worden woorden die een bepaalde drempelwaarde overschrijden dynamisch aan de woordenschat toegevoegd. Hierdoor kan het systeem geleidelijk nieuwe concepten, namen en domeinspecifieke termen integreren zonder dat de tokenizer volledig opnieuw getraind hoeft te worden.

Codering vindt plaats door bekende volledige woordtokens te koppelen aan hun ID's. Onbekende woorden worden ontleed in tekens, die ofwel worden gekoppeld aan bestaande tekentokens of worden vervangen door <unk>. Decoderen keert dit proces om door woorden te reconstrueren uit hun voorvoegsels.

Over het algemeen is deze tokenizer opzettelijk eenvoudig gehouden en mist hij veel functies van moderne tokenisatiemethoden. Hij voert geen subwoordsegmentatie, byte-niveau codering of statistische optimalisatie uit. Desondanks dient hij als een eenvoudige demonstratie van hoe een taalmodel een groeiende woordenschat kan onderhouden en zich in de loop der tijd kan aanpassen aan nieuwe taalkundige input, wat aansluit bij de doelstellingen van onze architectuur op het gebied van continu leren.

3 Relationeel wereldmodel

Om de dynamiek van het systeem, die continu leert, aan te vullen, introduceren we een lichtgewicht relationeel wereldmodel (RWM) dat eenvoudige relationele structuren van de vorm (onderwerp, relatie, object) opslaat en ophaalt. Het doel van deze module is niet om volledig symbolisch redeneren of het construeren van een grootschalige kennisgrafiek te bereiken, maar eerder om een minimaal mechanisme te bieden waarmee het model in de loop der tijd gestructureerde kennis kan vergaren.

Het RWM-model houdt een set knooppuntrepresentaties bij die overeenkomen met entiteiten die tijdens de training zijn tegengekomen. Wanneer een nieuwe entiteitsvector wordt aangeleverd, koppelt het model deze aan een bestaand knooppunt op basis van cosinusgelijkheid of creëert het een nieuw knooppunt als er geen voldoende vergelijkbare representatie bestaat. Dit stelt het systeem in staat om geleidelijk een compact, op gelijkenis gebaseerd geheugen van concepten op te bouwen. Het model slaat ook gerichte verbindingen tussen knooppunten op, elk voorzien van een annotatie met een geleerde relatie.

Machine Translated by Google

inbedding en een betrouwbaarheidsscore. Deze randen vertegenwoordigen eenvoudige relationele feiten die zijn afgeleid van de interne activaties van het model.

Om informatie door de grafiek te verspreiden, voert de RWM een klein aantal berichtuitwisselingsstappen uit. Voor elke rand wordt een bericht berekend op basis van het bronknooppunt en de relatie-embedding, en vervolgens samengevoegd in het bestemmingsknooppunt. Dit proces werkt de knooppuntstatussen bij en zorgt ervoor dat de relationele context toekomstige query's kan beïnvloeden. Hoewel het berichtuitwisselingsmechanisme opzettelijk eenvoudig is, biedt het een functionele demonstratie van hoe gestructureerde kennis kan worden geïntegreerd in een neuraal systeem voor continu leren.

Bij het opvragen van gegevens uit het RWM-model vergelijkt het model een invoer-entiteitsvector met alle opgeslagen knooppunten en haalt de meest vergelijkbare op, verrijkt met relationele context via berichtuitwisseling. Deze opgehaalde representatie kan vervolgens worden samengevoegd met de interne conceptrepresentatie van het model om een vorm van relationele verankering te bieden.

Over het algemeen is het relationele wereldmodel opzettelijk eenvoudig gehouden en niet bedoeld om te concurreren met volwaardige kennisgrafieksystemen of grafische neurale netwerken.
Het dient daarentegen als een minimaal, biologisch geïnspireerd prototype dat laat zien hoe relationele structuren kunnen worden opgebouwd, bijgewerkt en opgevraagd tijdens het voortdurende leerproces van een taal.

3.1 Relationele poort

Om te controleren hoe relationele kennis de interne representaties van het model beïnvloedt, introduceren we een klein poortmechanisme. De relationele poort berekent een scalaire waarde tussen 0 en 1 op basis van de gecombineerde conceptrepresentatie.
Deze waarde bepaalt hoe sterk de opgehaalde relationele context in de verborgen toestand van het model moet worden geïntegreerd.

De gate is geïmplementeerd als een enkele lineaire projectie gevolgd door een sigmoid-activeringsfunctie, waardoor deze computationeel goedkoop en gemakkelijk te trainen is. Ondanks zijn eenvoud biedt de gate een belangrijke mate van flexibiliteit: het model kan ervoor kiezen om sterk te vertrouwen op relationeel geheugen wanneer dit nuttig is, of het te negeren wanneer de opgehaalde informatie irrelevant of onzeker is.

Dit mechanisme weerspiegelt cognitieve theorieën die suggereren dat mensen selectief contextuele of relationele kennis integreren, afhankelijk van de taakvereisten. In onze architectuur zorgt de Relationele Poort ervoor dat relationele informatie de voorspellingen van het model verbetert zonder de kernrepresentaties ervan te overbelasten.

Machine Translated by Google

4 Conceptextractie

Om het model te laten samenwerken met het relationele wereldmodel, introduceren we een lichtgewicht conceptextractor die grove semantische rollen identificeert binnen een reeks tokenrepresentaties. Het doel van deze module is niet om volledige syntactische parsing of taalkundige analyse uit te voeren, maar om een eenvoudig mechanisme te bieden voor het extraheren van subject-actie-object (SVO)-tripletten uit de verborgen toestanden van het model.

Gegeven een reeks token-embeddings berekent de Concept Extractor drie onafhankelijke aandachtsverdelingen: één voor het onderwerp, één voor de actie en één voor het object. Elke verdeling wordt gegenereerd door een kleine lineaire scorekop, gevolgd door een softmax over de tokendimensie. Deze aandachtsgewichten bepalen welke tokens het sterkst bijdragen aan elke semantische rol.

Voor elke rol past de module een geleerde lineaire projectie toe op de token-toestanden en berekent een gewogen gemiddelde met behulp van de corresponderende aandachtsverdeling. Dit levert drie vectoren op: een subjectvector, een actievector en een objectvector. Deze vectoren dienen als compacte conceptuele samenvattingen van de invoersequentie en kunnen worden opgeslagen in of opgevraagd bij het relationele wereldmodel.

Hoewel dit mechanisme opzettelijk eenvoudig is en niet de volledige complexiteit van de syntaxis van natuurlijke taal probeert te modelleren, biedt het een functionele en computationeel voordelige manier om relationele structuur te extraheren uit interne activaties. In de praktijk fungeert de Concept Extractor als een brug tussen de continue representaties van het model en het discrete relationele geheugen, waardoor het systeem gestructureerde kennis kan vormen en ophalen tijdens continu leren.

Machine Translated by Google

4.1 Betrouwbaarheidsschatting

Om het model een lichtgewicht mechanisme te bieden voor het schatten van zijn eigen onzekerheid, voegen we een klein betrouwbaarheidsnetwerk toe. Deze module neemt als invoer de verborgen toestand van het model samen met de voorspelde uitvoerverdeling en produceert een scalaire betrouwbaarheidswaarde tussen 0 en 1. Het netwerk is opzettelijk eenvoudig: het concateneert de verborgen representatie met de softmax-genormaliseerde logits, verwerkt deze via een klein feed-forward netwerk, en Past een sigmoïde activeringsfunctie toe om de uiteindelijke betrouwbaarheidsscore te verkrijgen.

Hoewel minimaal, stelt dit onderdeel het systeem in staat om de betrouwbaarheid te meten. Een voorspelling kan nuttig zijn voor latere beslissingen, zoals bijvoorbeeld geheugenbeheer. opslag, relationele updates of selectieve consolidatie. Het ConfidenceNet is Niet ontworpen als een gekalibreerde onzekerheidsschatter, maar eerder als een lichtgewicht instrument. Een heuristiek die het model een basisidee geeft van wanneer het waarschijnlijk correct is.

Machine Translated by Google

5 Werkgeheugen

Om redeneren op korte termijn te ondersteunen en vluchtige informatie in de tijd te bewaren, introduceren we een lichtgewicht werkgeheugenmodule, geïnspireerd op cognitieve theorieën over het menselijk werkgeheugen. Het doel van deze component is niet om volledige terugkerende verwerking of aandacht voor een lange context te repliceren, maar om een kleine, snelle en differentieerbare geheugenbuffer te bieden die een beperkt aantal conceptuele representaties kan opslaan en bijwerken tijdens inferentie.

Het werkgeheugen bestaat uit een vast aantal geheugenplaatsen, die elk worden weergegeven als een leerbare vector. Aan het begin van een sequentie worden deze plaatsen geïnitialiseerd met een set geleerde standaardtoestanden. Wanneer het model een queryvector ontvangt – doorgaans afgeleid van de huidige verborgen toestand – voert de module twee bewerkingen uit: een leesbewerking en een schrijfbewerking.

Voor het lezen berekent de module aandachtsgewichten tussen de query en elke geheugenplaats met behulp van een eenvoudige dotproduct-gelijkenis. Deze gewichten worden genormaliseerd met een softmax en gebruikt om een gewogen gemiddelde van de geheugeninhoud te produceren, wat resulteert in een compacte leesvector. Deze leesvector geeft het model een samenvatting van de meest relevante informatie die momenteel in het werkgeheugen is opgeslagen.
geheugen.

Voor het schrijven gebruikt de module de query om te bepalen waar en wat er geschreven moet worden. Een geleerde adresprojectie genereert een verdeling over geheugenplaatsen, die aangeeft welke plaatsen bijgewerkt moeten worden. Een apart poortmechanisme bepaalt hoe sterk de nieuwe informatie het bestaande geheugen moet beïnvloeden. De schrijfinhoud zelf wordt gegenereerd door een klein projectienetwerk dat op de query wordt toegepast. De uiteindelijke geheugenupdate wordt berekend als een gepoorte, plaatsgewijze additieve wijziging, waardoor het geheugen zich in de loop van de tijd soepel kan ontwikkelen.

Hoewel opzettelijk eenvoudig, biedt deze module voor het werkgeheugen het model een flexibel mechanisme voor het behouden van context op de korte termijn, het opslaan van tussenliggende concepten en het ondersteunen van redeneringen in meerdere stappen. Het is niet bedoeld ter vervanging van aandachtssystemen voor grote contexten of externe geheugensystemen, maar eerder als een compacte, biologisch geïnspireerde buffer die het vermogen van het model om informatie te volgen en te manipuleren tijdens het voortdurende leerproces van een taal verbetert.

Machine Translated by Google

6 Vloeibare zelfaandacht

Om adaptieve en toestandsafhankelijke dynamiek in het aandachtmechanisme te introduceren, gebruiken we een vereenvoudigde Liquid Self-Attention-module. In tegenstelling tot standaard softmax-aandacht, die genormaliseerde dot-productgewichten berekent over alle Bij sleutel-waardeparen vervangt deze variant de softmax-kernel door een positieve, elementgewijze niet-lineaire transformatie. Concreet worden zowel zoekopdrachten als sleutels doorgegeven. via een vloeibare activeringsfunctie ÿ(x) = ELU(x)+1, wat strikt positieve resultaten garandeert kenmerken en het mogelijk maken van een vorm van multiplicatieve gating die lijkt op continue-tijd vloeibare neurale dynamiek.

De aandachtsberekening volgt de structuur van lineaire aandacht: getransformeerde sleutels en waarden worden gecombineerd in een globale KÿV- matrix, en elk De query communiceert met deze samenvatting via efficiënte matrixvermenigvuldigingen. vermijdt de kwadratische kosten van standaard aandacht en introduceert vloeiendere, meer stabiele interacties tussen tokens. Een normalisatieterm wordt berekend met behulp van de getransformeerde sleutels, waardoor wordt gewaarborgd dat de resulterende aandachtoutput goed geschaald blijft.

Om het model in staat te stellen te reguleren hoeveel de output van de vloeibare aandacht zou moeten bedragen Om de uiteindelijke weergave te beïnvloeden, voegen we een aangeleerd poortmechanisme toe. De sigmoidpoort mengt de aandachtsoutput met de oorspronkelijke input, waardoor de model om te interpoleren tussen puur feed-forward gedrag en volledig dynamisch gedrag Aandachtgestuurde updates. Dit filtermechanisme zorgt voor extra stabiliteit. en voorkomt dat de aandachtmodule de onderliggende representatie overweldigt wanneer de aangeleerde dynamiek onzeker is.

Al met al is deze Liquid Self-Attention-module opzettelijk licht van gewicht en experimenteel. Het is niet de bedoeling om de volledige expressiviteit van continue-tijd vloeistofnetwerken te repliceren, maar biedt in plaats daarvan een eenvoudige en computationeel efficiënte benadering. een manier om adaptieve, niet-lineaire dynamiek in het aandachtmechanisme te introduceren. In de praktijk verbetert dit het vermogen van het model om contextafhankelijke interacties vast te leggen, terwijl de stabiliteit tijdens continu leren behouden blijft.

7. Episodisch geheugen in de hippocampus

Om snel leren en het opslaan van recente ervaringen te ondersteunen, hebben we het volgende opgenomen: Een lichtgewicht hippocampusmodule die functioneert als een buffer voor episodisch geheugen. Dit onderdeel is geïnspireerd op de rol van de biologische hippocampus bij het vastleggen van kortstondige maar waardevolle ervaringen voordat ze worden geconsolideerd in het geheugen. langetermijngeheugen. In tegenstelling tot grote replaybuffers of complexe geheugensystemen is onze implementatie opzettelijk eenvoudig en ontworpen als een bewijs van concept.

De hippocampus slaat onbewerkte zinnen op samen met een prioriteitsscore, die weerspiegelt hun geschatte belang of relevantie op het moment van codering. Nieuw Afleveringen worden aan het geheugen toegevoegd, en wanneer de buffer zijn maximale capaciteit overschrijdt, wordt de buffer leeggehaald. capaciteit, de oudste gegevens worden verwijderd. Dit zorgt ervoor dat het geheugen behouden blijft.

Machine Translated by Google

gericht op recente of prioritaire ervaringen, wat de vluchtige aard van het biologische episodische geheugen weerspiegelt.

Tijdens het afspelen selecteert de module afleveringen met behulp van gewogen willekeurige selectie, waarbij de kans om een aflevering te kiezen evenredig is aan de opgeslagen prioriteit. Dit stelt het systeem in staat om belangrijke of verrassende ervaringen vaker opnieuw te bekijken, terwijl de diversiteit in de afgespeelde afleveringen behouden blijft. Als prioriteiten niet beschikbaar zijn of niet correct zijn, schakelt de module over op uniforme steekproefneming om de stabiliteit te waarborgen.

Hoewel minimaal, biedt deze hippocampusbuffer een praktisch mechanisme voor het herhalen van ervaringen tijdens slaapgeïnduceerde consolidatie. Het stelt het model in staat om eerdere input te herhalen, nuttige patronen te versterken en vergeetachtigheid tegen te gaan zonder dat grootschalige opslag of complexe ophaalmechanismen nodig zijn. Het ontwerp legt de nadruk op eenvoud, biologische plausibiliteit en compatibiliteit met continu leren.

8 Spiegelmodel en gesimuleerde spiegelneuronen

Als aanvulling op het hoofdtaalmodel introduceren we een secundair spiegeltaalmodel (MirrorLM) dat tot doel heeft de functionele rol van biologische spiegelneuronen te simuleren. In de neurowetenschappen reageren spiegelneuronen zowel wanneer een organisme een actie uitvoert als wanneer het dezelfde actie door anderen observeert. Men denkt dat ze imitatieleer, foutmonitoring en de interne simulatie van gedrag ondersteunen. Ons MirrorLM is ontworpen als een computationele analogie van dit mechanisme.

Het MirrorLM-model verwerkt dezelfde invoersequentie als het hoofdmodel, maar draagt niet direct bij aan de voorspelling van tokens. In plaats daarvan volgt het interne toestandsovergangen en berekent het een vorm van voorspellingsfout tussen opeenvolgende verborgen toestanden. Deze voorspellingsfout fungeert als een indicator voor "verrassing" of een discrepantie tussen de verwachte en waargenomen interne dynamiek, analoog aan hoe spiegelneuronen sterker vuren wanneer een waargenomen actie afwijkt van een verwacht patroon.

Om zijn gedrag in de loop van de tijd aan te passen, bevat de MirrorLM een kleine meta-leermodule die twee belangrijke parameters bijwerkt: een effectieve leersnelheid en een schaalingsfactor voor snelle terugkerende gewichten. Deze updates worden aangestuurd door het waargenomen verlies en de verrassingssignalen van het model, waardoor de MirrorLM zijn interne dynamiek kan aanpassen als reactie op onverwachte of informatieve ervaringen. Op deze manier functioneert de MirrorLM als een zelfreflecterend systeem dat het gedrag van het hoofdmodel monitort en informatie op metaniveau over de voortgang van het leerproces verzamelt.

Hoewel opzettelijk eenvoudig, biedt deze op spiegels geïnspireerde architectuur een biologisch gemotiveerd mechanisme voor interne simulatie en foutgestuurde aanpassing. Het stelt het systeem in staat verrassende patronen te detecteren, de leerdynamiek te moduleren en slaapgebaseerde consolidatie te ondersteunen, wat de veronderstelde rol van spiegelneuronen in de menselijke cognitie weerspiegelt.

Machine Translated by Google

9. Consolidatie op basis van slaap

Een centraal onderdeel van onze architectuur is een op slaap gebaseerd consolidatiemechanisme, geïnspireerd op biologische geheugensystemen. Bij mensen speelt slaap een cruciale rol. rol in het stabiliseren van nieuw verworven kennis, het herbeleven van episodische ervaringen, en het integreren van relationele structuren in het langetermijngeheugen. Ons model hanteert Dit perspectief wordt geïntroduceerd door een offline consolidatiefase waarin het Mir-rorLM, de hippocampusbuffer en het relationele wereldmodel met elkaar interageren om de verfijning te verbeteren. de parameters van het hoofdmodel zonder directe blootstelling aan nieuwe externe input.

Tijdens de slaap neemt het systeem fragmenten uit het geheugen van de hippocampus als basis. waarbij verrassende of waardevolle ervaringen voorrang krijgen. Deze episodes worden opnieuw gecodeerd. door de MirrorLM, die fungeert als een interne simulator. De MirrorLM doet Het is niet de bedoeling om tokens direct te voorspellen; in plaats daarvan volgt het de evolutie ervan. verborgen toestanden en berekent een voorspellingsfoutsignaal dat de afwijking weerspiegelt. tussen de verwachte en de waargenomen interne dynamiek. Deze fout dient als een proxy. voor "verrassing", analoog aan de verhoogde neurale activiteit die wordt waargenomen in biologische systemen. Spiegelneuronen tijdens onverwachte gebeurtenissen.

De voorspellingsfout en het reconstructieverlies bij herhaalde afleveringen zijn De gegevens worden ingevoerd in een kleine meta-leermodule binnen MirrorLM. Deze module past twee belangrijke parameters aan: een effectieve leersnelheid en een schaalingsfactor voor snelle terugkerende gewichten. Deze aanpassingen stellen het systeem in staat om te moduleren hoe agressief het informatie consolideert tijdens de slaap. Episodes met een hoge mate van verrassing leiden tot sterkere consolidatie-updates, terwijl bekende of weinig verrassende gebeurtenissen minimale veranderingen teweegbrengen. Deze dynamiek weerspiegelt biologische theorieën waarin slaap geeft prioriteit aan de integratie van nieuwe of zwak gecodeerde ervaringen.

Het belangrijkste model profiteert op twee manieren van slaap. Ten eerste versterken herhaalde episodes de voorstellingen die anders wellicht vergeten zouden worden, waardoor catastrofale gevolgen worden verzacht. interferentie. Ten tweede wordt het relationele wereldmodel tijdens de slaap bijgewerkt, waardoor relationele structuren die tijdens het wakker zijn zijn geëxtraheerd, kunnen worden versterkt. Gereorganiseerd of gesnoeid. De combinatie van episodische herhaling, relationele verfijning en aanpassing op meta-niveau stelt het systeem in staat nieuwe kennis te integreren. zonder eerder opgedane informatie te destabiliseren.

Hoewel vereenvoudigd, biedt dit op slaap gebaseerde consolidatiemechanisme een Een biologisch geïnspireerd raamwerk voor continu leren. Het stelt het model in staat om Eerdere ervaringen herhalen, de interne dynamiek aanpassen en de langetermijnstabilisatie bevorderen representaties zonder dat grootschalige omscholing nodig is. In de praktijk dient slaap als een krachtige offline fase waarin het systeem zijn kennis reorganiseert, de generalisatie verbetert en zich voorbereidt op toekomstig leren.

10 Testtijd Leren

Een kenmerkend aspect van onze architectuur is het vermogen om continu te blijven leren. inferentie, een vaardigheid die we aanduiden als leren tijdens de test. In tegenstelling tot grote taal modellen, die werken met bevroren parameters zodra de training is voltooid, onze Het systeem past zijn interne representaties, relationele structuren en episodische patronen aan.

Machine Translated by Google

geheugen, zelfs tijdens het verwerken van nieuwe invoer. Dit ontwerp is geïnspireerd op biologische principes. cognitie, waarbij mensen hun begrip van de wereld voortdurend bijwerken.
naarmate ze nieuwe informatie tegenkomen, ongeacht of ze zich in een formele context bevinden.
"leerfase."

Tijdens de testfase blijven verschillende onderdelen van het model van plastic.
De dynamische tokenizer breidt zijn woordenschat uit wanneer nieuwe woorden of concepten worden toegevoegd. verschijnen, waardoor het model nieuwe taalkundige elementen kan weergeven zonder opnieuw te hoeven trainen. Het relationele wereldmodel werkt zijn grafstructuur bij door nieuwe elementen toe te voegen. entiteiten en relaties die zijn geëxtraheerd uit de Concept Extractor, waardoor het systeem
Om in de loop der tijd gestructureerde kennis te vergaren. De hippocampus slaat geheugen op. verrassende of prioritaire gebeurtenissen die tijdens de inferentie worden aangetroffen, waardoor latere consolidatie tijdens de slaap.

Cruciaal is dat MirrorLM een actieve rol speelt tijdens het leerproces in de testfase.
Het model verwerkt nieuwe sequenties, MirrorLM volgt interne toestandsovergangen en berekent voorspellingsfouten die weergeven hoe onverwacht of informatief de voorspellingen zijn. de input is. Deze verrassingssignalen beïnvloeden de prioriteit die wordt toegekend aan episodische opslag en vormgeving van de meta-leerdynamiek die later het model zal aanpassen parameters tijdens de slaap. Op deze manier verwerkt het systeem niet alleen de invoer, maar ook Het evalueert ook in realtime zijn eigen onzekerheid en leerbehoeften.

Testleren biedt verschillende voordelen. Ten eerste stelt het het model in staat om zich aanpassen aan domeinverschuivingen, nieuwe woordenschat en nieuwe relationele structuren zonder Ten eerste vereist het grootschalige omscholing. Ten tweede ondersteunt het continu leren door ervoor te zorgen dat belangrijke ervaringen direct worden vastgelegd in plaats van vergeten. vóór de volgende consolidatiefase. Ten derde maakt het een meer mensachtig leertraject mogelijk, waarbij kennis geleidelijk en contextueel wordt opgebouwd.
in plaats van in afzonderlijke trainingsperioden.

Hoewel onze implementatie opzettelijk eenvoudig is, toont ze aan dat
Taalmodellen kunnen baat hebben bij het behouden van een zekere mate van plasticiteit tijdens inferentie. Door het systeem te laten leren tijdens de testfase, komen we dichter bij een
Een biologisch geïnspireerd raamwerk waarin waarneming, geheugen en leren continu en interactief samenwerken.

11 Curriculumleren

Om een stabiele verwerving van taalkundige structuren te ondersteunen en de belasting te verminderen Bij catastrofale storingen maakt ons systeem gebruik van een eenvoudige maar effectieve vorm van curriculumleren. Geïnspireerd door de ontwikkeling van de menselijke taal, is het model niet tegelijkertijd blootgesteld aan alle vormen van taalkundige complexiteit. In plaats daarvan komt het in aanraking met geleidelijk aan steeds moeilijkere patronen, waardoor de interne representaties, het relationele geheugen en de werkgeheugenmechanismen zich kunnen ontwikkelen voordat
Uitgedaagd worden met moeilijkere opdrachten.

Het lesprogramma begint met korte, syntactisch eenvoudige zinnen die een duidelijke onderwerp-werkwoord-objectstructuur benadrukken. Deze eerste voorbeelden helpen de
De conceptextractor en het relationele wereldmodel vormen robuuste initiële representaties van entiteiten en relaties. Naarmate de training vordert, wordt het model geleidelijk aan verbeterd.

Machine Translated by Google

Er wordt kennisgemaakt met langere sequenties, meer abstracte relationele patronen en een steeds diverser vocabulaire. Omdat de tokenizer dynamisch kan groeien, breidt het curriculum het lexicon van het model op natuurlijke wijze uit, parallel aan de conceptuele ontwikkeling ervan.
begrip.

Het leren van het curriculum staat ook in nauw verband met de mechanismen voor het leren tijdens toetsen en de op slaap gebaseerde consolidatie van het systeem. Tijdens de inferentie kan het model komt zinnen tegen die het huidige competentieniveau overstijgen. Deze ervaringen worden met hoge prioriteit opgeslagen in het hippocampusgeheugen, waardoor wordt gewaarborgd dat
Ze worden tijdens de slaap herhaald. Op deze manier is het leerplan niet strikt vooraf vastgelegd, maar past het zich aan de eigen onzekerheid en verrassingssignalen van het model aan. Moeilijk of
Nieuwe voorbeelden die "in de praktijk" worden aangetroffen, maken deel uit van de volgende consolidatie. De cyclus breidt het curriculum effectief uit op basis van praktijkervaring.

Dit adaptieve curriculum weerspiegelt het menselijke leerproces, waarbij blootstelling aan nieuwe informatie leidt tot een betere leerervaring.

De ontwikkeling van taalstructuren verloopt geleidelijk, is contextafhankelijk en wordt versterkt door herhaalde ervaringen. Hoewel onze implementatie opzettelijk eenvoudig is,
Dit toont aan dat zelfs een eenvoudig curriculum de stabiliteit aanzienlijk kan verbeteren, vergeetachtigheid kan verminderen en de ontwikkeling van gestructureerde relationele relaties kan ondersteunen.
Kennis opdoen in een omgeving waar continu leren centraal staat.

Machine Translated by Google

12 Analyse van de lengte van de intrinsieke context

Om de intrinsieke geheugencapaciteit van de architectuur te evalueren, hebben we gemeten hoe ver informatie zich door het ongetrainde model kan verspreiden. Met behulp van de eerder beschreven procedure hebben we een enkel informatief token op verschillende afstanden van de eindpositie ingevoegd en de verandering in de uitvoerlogits geregistreerd.
De resulterende gevoeligheidscurve is weergegeven in figuur 1.

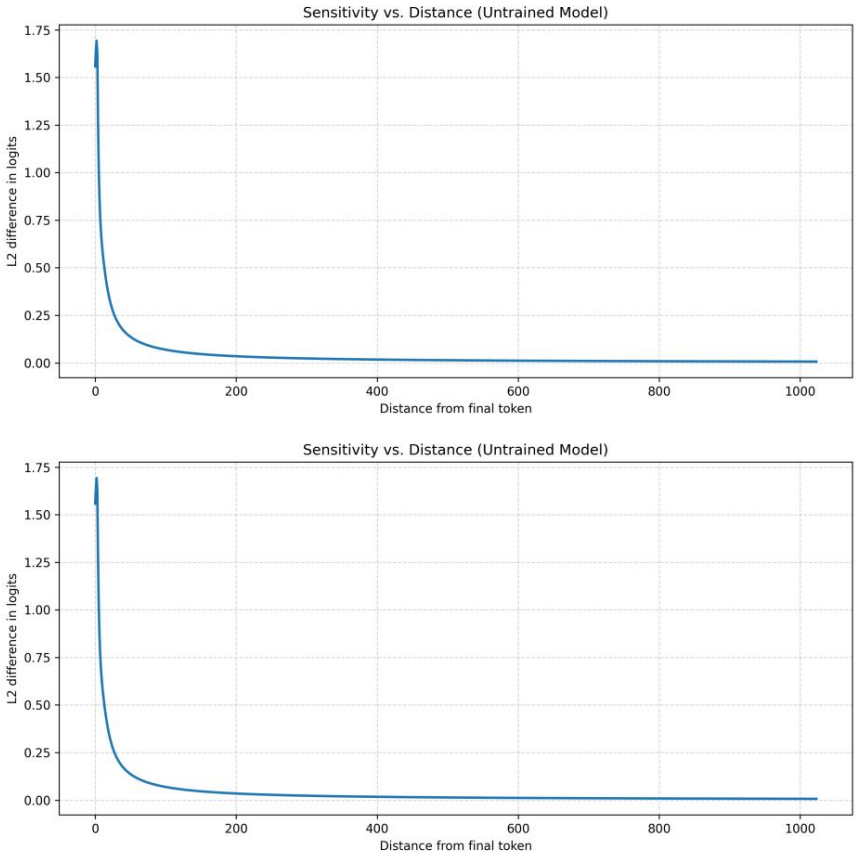

Figuur 1: Gevoeligheid van het ongetrainde model voor een enkel informatief token dat op toenemende afstand van de eindpositie is geplaatst. De curve toont het L2-verschil in uitvoerlogits tussen een basissequentie en een sequentie die het informatieve token bevat.

Verrassend genoeg vertoont het model een veel groter effectief contextbereik dan de nominale architecturale venstergrootte zou doen vermoeden. Zelfs zonder training behoudt LiquidLM een meetbare gevoeligheid voor tokens die meer dan honderd posities verwijderd zijn van het voorspellingspunt. Dit gedrag is het resultaat van de combinatie van vloeibare zelfaandacht, terugkerende dynamiek en gating-mechanismen.

Machine Translated by Google

anismen, die er samen voor zorgen dat informatie zich soepel over lange afstanden kan verspreiden

overspanningen.

De geleidelijke afname van de gevoeligheidscurve geeft aan dat het model niet afhankelijk is van een harde afsnijding, maar in plaats daarvan een continue geheugenstaart vertoont. Dit staat in contrast met standaard transformer-architecturen, waarbij ongetrainde aandachtsgewichten vaak instorten tot bijna uniforme patronen die er niet in slagen onderscheidingen over lange afstanden te behouden. De resultaten tonen aan dat de architectonische keuzes in LiquidLM sterke inductieve bias bieden voor het omgaan met afhankelijkheden over lange afstanden, zelfs voordat er enig leerproces heeft plaatsgevonden.